第三问 DGX 功率更新说明

更新边界

上游采用当前 task2/runs/experiment 及 Work 1 配置，只读验证。旧第三问代码、配置、逐请求实验、图表、报告和 PDF 已归档于 archives/legacy_power_175_250_20261017，不与本轮实验混合。旧数据准备包保留为冻结基准，新版源适配与派生输入全部在 task3_model 内。

六台常开 8-GPU 主机：DE/FR/ES 各 S/L 一台；每池仍只准入一个 GPU 服务槽位。安装 48 张 GPU 不意味着 48 个可调度副本。每台共享 1500W、单 GPU 空闲 175W、忙碌 760W、PUE1.2；空闲整机 2900W、单槽位运行时 3485W，12 小时固定空闲电量 250.56kWh。不可用仅阻止新准入，主机仍开机。物理主机底座只计一次，增加准入槽位不复制主机。服务器配置中的 busy/idle 是整机单槽位状态的兼容别名，差值 585W 才是每个运行请求的 IT 增量。

冻结与验证

7335 个请求 ID、时间顺序/间隔、截止/等待类别、priority、来源地区、S/L、质量预测、服务时间和公共随机扰动均保持。唯一变化的原请求字段为 estimated_energy_kwh，现为 585×PUE× 估计服务秒/3.6e6。全部 14670 个 S/L 质量预测通过当前已保存 Pre 模型重放，未重新训练或修改阈值。Code/Math/未知来源回退 L 保留。

21 项原合成接口测试仍执行；原全数据验证器的旧路径/旧功率字段明确标为被当前源验证替代。新源检查重放路由、训练长度、服务代理和能耗。新输入指纹包含上游配置/源码/权重/路由、物理主机表与资源合同；上游更改后必须先 audit，不能继续消费旧派生数据或缓存。

三类数字必须区分

下表均为完整 7335 请求、三个公共扰动重复的均值。“旧计划新功率计价”只对归档账本重计固定底座与增量；“新版重新调度”来自实际重跑 MILP-MPC、其他策略及 DES。当前正式结果采用最后一类。

策略	旧口径 CO2e/g	旧计划新功率计价/g	新版重新调度/g	新版电量/kWh	新版 P95/s	新版违反/%
Fixed	2512.685173	41374.061915	41374.061915	252.289256	5.217	0.5771
Greedy	2502.066937	41287.861296	41288.146559	252.298557	4.8889	0.2772
Oracle	2494.696094	41230.678352	41230.781144	252.304027	1800.4554	0.0227
MPC	2495.029071	41233.073708	41233.013855	252.302935	14.8803	0.0773

对照	结果类型	净减排/g	总量减排/%
Fixed	旧功率实验	17.656102	0.702679
Fixed	旧计划新功率计价	140.988206	0.340765
Fixed	新功率重新调度	141.04806	0.340909
Greedy	旧功率实验	7.037865	0.281282
Greedy	旧计划新功率计价	54.787587	0.132697
Greedy	新功率重新调度	55.132705	0.133532

即使使用相同请求和服务扰动，新的增量碳/网络权衡与碳量化会改变 MILP 地区/开始时刻，最终完成和违反率也可能变化。不能用解析计价表替代新版策略实验，也不能把固定计划不变的延迟当成重新优化后的延迟。

数学与实验解释

对每台主机，P_IT(t)=P_shared+8P_GPU,idle+(P_GPU,busy-P_GPU,idle)b(t)。固定总能量为所有主机空闲底座加各请求忙碌增量，再加网络及单独控制。固定主机与 12 小时窗口使共享底座对候选决策是常数，但它必须

进入设施总碳分母。碳按实际地区/小时积分，L 服务时长不再乘 3。现有 MILP 唯一分配、非抢占占用、最大等待、完成截止和因果预测约束保留。

边界、预测误差、需求及故障结果均重新运行，见 RESULTS_zh.md 与 boundary_classification.csv；不得沿用旧版 0.70268% 或旧失效阈值。安装 GPU、服务槽位、主机数量、观察窗口在策略间完全一致。正碳收益同时需满足共同完成输入与服务约束，非零违反不能判作严格部署合格。

操作与限制

在 task3_model 目录运行 python -B -X utf8 run_all.py –phase all；仅刷新已完成新版图文报告用–phase report。按阶段的 audit/test/pilot/scale/experiments/full-stress 命令不变。正式上游位置在 configs/upstream.json，模型参数在 configs/core.json。更新 PDF 位于 output/pdf_dgx；旧 PDF 和旧对话解释属于旧功率版本。

1500W 共享/175W 空闲为假设，760W 为特定公开基准配置代理；不是 GPT-4/Mixtral 实测。真实碳数据不变，GWP 具体快照版本和 as-of 历史仍未验证，不能称真实部署减排。旧全数据验证器没有被伪装为通过；新版具体测试数量、求解状态和完成组合数以 VALIDATION_REPORT.md 为准。