第三问：完整求解过程、实际结果与运行指南

当前为 DGX 整机资源版本；旧 175/250W 结果已归档。当前输入在 results/data，上游接口在 configs/upstream.json，新版 PDF 在 output/pdf_dgx；不要运行旧数据准备生成器来覆盖基准。导出 PDF 用 python -B -X utf8 pdf_export/export_pdfs.py。

本文解释当前已经实现和运行的版本，不将建议实验写成已完成实验。数值来自本目录的最终实验 CSV；重新运行或改变配置后，应以新生成的 RESULTS_zh.md、CSV 和逐请求记录为准。Task 1、Task 2、冻结路由和原数据准备文件均不在本指南的修改范围内。

一、问题如何转化为可计算的研究

第二问回答“用 S 还是 L”，第三问固定这个答案，只回答“放在哪里、什么时候开始、排多久”。系统链条为：

RouterBench 历史请求
→ 第二问冻结的 Selected_finite_sample_guard 选模
→ 事前资源估计 + 合成到达过程 + 服务类别
→ 时间对齐后的请求、地区资源、实际碳数据及因果预测
→ Fixed / Greedy / Oracle / MPC 调度
→ 同一秒级事件 DES 执行
→ 同一能量账本及实际逐小时碳积分
→ 配对实验、服务合格判定、图表与论文结论

研究问题	核心比较	必须同时观察的指标
RQ1：时空调度能否节碳?	Fixed 与 Greedy/MPC	总 CO2e、完成率、服务违反率、固定空闲底座
RQ2：复杂优化是否优于贪心?	Greedy 与 MPC，叠加负载及故障	净碳差、延迟、失败、求解及回退
RQ3：等待换来多少减排?	改变允许延迟，参考 Oracle	总碳、主动等待、P95、服务约束
RQ4：什么时候不值得?	改变碳差异、网络、预测和控制开销等	服务全部合格且 Greedy−MPC 总碳大于 0

这里的 S/L 分别继承 Mixtral-8x7B 和 GPT-4-1106-preview 的历史路由/质量标签，属于抽象计算服务。它不表示能够指定商业 GPT-4 的底层服务器地区，也不表示功率或推理时间已经通过真实硬件测量。

二、Phase 0：先核对真实材料，再建立可用输入

2.1 冻结第二问

直接复用 Selected_finite_sample_guard 的测试分区逐请求决策，不重新训练、不重新选 S/L、不调整阈值、不打开 Post 级联。Code/Math 及未知任务仍回退 L，General 仍沿用冻结 Pre-LightGBM 规则。完整输入 7335 个，S431、L6904；这是校验结果，不是逐请求硬编码决策。

q_hat_S/q_hat_L 随原请求保留，但第三问不借此更换模型。当前真实质量、回答文本及真实输出长度不进入调度器。历史质量在 DES 结束后才由评价专用表接入，固定输入群体的平均历史质量始终为 0.776141786。

审计及复用范围包括第二问研究报告、逐请求决策、预测模型及资源代码、数据准备配置/验证器/时间对齐器/资源合同。未找到指定的比赛 PDF，问题表述采用用户提供的第三问原文。当前版本上游文件 SHA256 保持不变；旧 327 项快照保存在归档。

2.2 真实碳数据

DE、FR、ES 原文件各 8760 小时，合计 26280 行，覆盖 2025 全年。源时间字符串虽没有 Z，但表头明确 UTC，读取时按 UTC 处理，不按本机时区猜测。检查碳值、关键空值、重复、每小时间隔和覆盖范围。

主实验使用提供方生命周期 gCO2eq/kWh，规范列名为 carbon_intensity_gco2e_kwh。direct CO2e 另存、另做敏感性实验。二者不混合，也不把 CO2e 转换成纯 CO2。兼容旧接口的 carbon_intensity_gco2_kwh 只是有 metadata 说明的历史列名别名。

DE/FR/ES 分别有 12/5/27 个提供方估计小时，标志原样保留，不将它们说成独立实测。快照没有精确的历史 GWP 因子版本或 2025 实时发布版本，均标为未验证，不伪造元数据。

2.3 对齐时间

原 2024-05-10 请求基准不改。复用原对齐器的纯函数，所有派生数据写入本模型的 `results/data/`。

日期选择规则预先确定为：先留 24 小时历史预测预热，再选最早共同完整窗口。因此当前锚点为 **2025-01-02 00:00:00 UTC**。保持 ID、到达顺序及间隔、S/L、相对 deadline、priority、资源估计、公共扰动及容量事件相对时刻不变。

这只是将 Azure 间隔形状的合成请求过程映射到真实碳曲线；不是实际发生于 2025 年的 RouterBench 业务。

2.4 将 actual 和决策预测隔开

主预测 Persistence 仅使用决策时已经结束的最近一小时观测，假设该小时结束即可见。未来各小时预测保持该值。扩展预测为过去同小时均值；历史不足时退回过去扩展均值。模拟预测误差是在合法预测上加固定键的乘性扰动，不是给未来 actual 加噪。

必须满足 `issued_at <= decision_time`，且使用的观测小时已结束。未来 actual 只进入环境排放核算和显式 Oracle。MPC 也看不到尚未到达的请求、尚未发生的服务扰动及未公告的未来故障。

因此这是对回溯快照的因果历史再预测，不是恢复真实 2025 运营预测档案。

三、Phase 1：继承资源估计，建立统一事件环境

3.1 事前服务时间

继承第二问的假设代理。令 `x=input_proxy/1000`，`y=(estimated_output_proxy−1)/1000`：

$$TTFT = 0.05 + 0.2x + 0.01x^2, \quad Decode = 8y + 0.1xy + 0.02y^2.$$

$$p_i = (TTFT + Decode)\alpha_{m_i}, \quad \alpha_S = 1,\ \alpha_L = 3.$$

输出代理来自训练集任务 × 模型历史长度聚合，不来自当前测试请求的实际回答长度。输入文件里的 `estimated_service_time_seconds` 已包含 S/L 倍率；DES 不得再乘 3。

实际执行时间为 `p_i × Z_i,rep`，其中 `Z=exp(N(−σ²/2,σ²))`、σ=0.15，均值 1。同请求同 rep 跨地区及策略使用同一实现，继承种子 20261016/20261017/20261018；优化器事前不能读取该实现。模型其他固定随机规则使用配置中的种子。

规划占用使用 `pbar_i=1.35 p_i`，这是额外的安全余量，只用于计划，不再次放大真实能耗。对数正态扰动有无界尾部，因此有限安全倍数不能保证随机零超时。

3.2 服务要求与服务器

类别	比例	完成预算	最大主动加排队等待	priority
realtime	40%	30 秒	5 秒	3
bounded_delay	40%	300 秒	120 秒	2
batch	20%	3600 秒	1800 秒	1

类别是独立于任务类型的仿真假设。Code/Math 不等同于紧急。deadline 始终是**完成截止时间**。priority 随输入保留；当前 MPC 批次按最早完成截止时间排序，目标不额外设置 priority 加权效用。

DE/FR/ES 各有 S、L 一个物理副本，共 6 个。每池一台常开 8-GPU 主机，整机空闲 2900W、单槽位忙碌 3485W、PUE1.2；只准入 1 个服务槽位。S 池不执行 L 任务。

三种可用性均为假设：normal 保持基础资源；local_failure 在 3600 秒关闭 DE-L 新准入、5400 秒恢复；high_load_capacity_reduction 在 7200 秒关闭 FR-L 及 ES-L 新准入、9000 秒恢复。容量下降时运行任务继续完成，停用副本不接新任务。不可用不等于断电。

网络单程延迟继承 0.05 秒控制延迟，再加本地 5ms、DE–FR 20ms、DE–ES 40ms、FR–ES 25ms。传输电量本地 1e−7、跨区 1e−6 kWh/请求。这些是显式假设，保留 allowed 接口。

3.3 DES 到底模拟了什么

`src/des.py` 使用堆式下一事件引擎，无需 SimPy。包含到达、路由、分发、传输完成、服务开始、完成、容量变化、MPC 重优化/承诺、等待过期、DeadlineMiss 等事件，按连续秒推进。

记录时间分解为：

$$intentional_delay = dispatch - (arrival + router),$$
$$queue_wait = start - (dispatch + network),$$
$$response = router + intentional_delay + network + queue_wait + actual_service.$$

这里主动延迟指标包含新增控制计算和策略持有时间；排队只从网络就绪后开始计。不把网络/路由延迟计两次。

一旦开始便非抢占，不在下一轮 MPC 重新启动。实际服务超出预估时，后续任务继续等待或失败，不会让同一个副本同时运行两项任务。已启动任务即使超过 deadline 也完成并标违反；未启动且已不可能满足等待/预计完成限制的请求明确失败。每个输入都有唯一终态。

四、Phase 2–4：四种策略、MILP 与 MPC

4.1 四种策略的含义

策略	地点/时间规则	可见信息
Fixed Local	来源地区，FCFS，不主动等低碳	当前请求与状态
Greedy	优先当前可用且预计可按时完成的低碳地区；否则考虑可排队地区，不主动找未来低碳时段	最近可见观测与当前状态
Oracle	完整未来信息下的有限候选、顺序离线 MILP 批次	未来请求、actual 碳及容量；仍不知道未来服务随机实现
MILP-MPC	只对已到达等待集合滚动安排地区与开始时刻	合法预测、当前资源、已承诺/运行占用

Oracle 不是全轨迹全局最优证书，不一定构成所有随机执行结果的下界。当前 Oracle 分批和候选限制下，个别压力组可能被 MPC 超过。

4.2 有限候选 MILP

在决策时刻 k，对待调度集合 `I_k`，设地区 r、兼容物理副本 j 及候选开始时刻 u。二元变量 `x_irju=1` 表示该分配；`z_i=1` 表示当前受限计划未分配。

唯一分配：

$$\sum_{r,j,u} x_{irju} + z_i = 1.$$

候选合法性：若选模/地区不允许、网络未就绪、超过等待、预计完成超时或新准入容量不允许，候选直接删除。保留的 u 满足：

$$u \geq \max(a_i + \ell_i + n_{ir},\ k + \tau_{control} + n_{ir}),$$
$$u \leq a_i + \ell_i + n_{ir} + w_i, \qquad u + \bar{p}_i \leq d_i, \qquad u + \bar{p}_i \leq k + H_{MPC}.$$

完整占用：将所有候选/预留开始与结束时刻切成基本区间 b，每个物理副本满足：

$$\sum_{i,u:[u,u+\bar{p}_i)\cap b\neq\emptyset} x_{irju} \leq 1 - B_{rmj}(b).$$

运行/已承诺任务通过固定占用 B 进入，不允许重排。它约束整个执行区间，不能只检查到达或开始时是否空闲。

候选碳成本：使用均值服务时长而非已实现噪声，对预测碳逐小时积分：

$$e_{irju} = \frac{PUE_r(P_{busy,r} - P_{idle,r})}{3.6 \times 10^6} \int_u^{u+p_i} \widehat{C}_r^k(s)ds + E_{ir}^{net}\widehat{C}_{ir}^{endpoints}.$$

共同固定空闲底座不影响候选选择，在最终评价仍完整计入。网络碳按两端 50/50 归属代理。随机跨小时的真实积分期望不一定等于这里的均值时长近似，DES 事后使用真实实现核算。

目标采用字典序：先尽量减少未分配，再最小化增量碳，再以较早开始打破平局。实现用微克量化碳成本、支配未分配系数和总量小于一个碳量化单位的开始排序项；不任意相加克、秒和美元。完整符号与等价目标见根目录 `MODEL_FORMULATION.md`。

候选包括最早可行、少量相邻服务间距、占用结束点、小时边界及最晚可行时刻。单请求有限问题精确枚举，其余 SciPy MILP/HiGHS。有限候选最优不等于连续时间原问题最优。

4.3 MPC 如何滚动

1. 到达/紧迫事件或周期 tick 触发，读取已到达、等待、运行、承诺和当前容量。
2. 按完成截止排序，取不超过 64 个等待请求。冻结选模。
3. 发布因果预测；未公告未来容量变化按当前可用容量持续预测。
4. 在 3 小时规划窗口建立有限候选 MILP，单次求解预算 0.2 秒。
5. 只提交承诺窗口内动作，较远候选保持未承诺，下一轮重新考虑。
6. DES 按实际容量和随机服务执行，释放资源；容量变化触发重新检查。
7. 无可行解、超时无解、未分配时明确回退到最早可行地区；确实不能完成则记录失败原因。

主周期为 5 分钟，同时有到达/紧迫事件触发和 0.5 秒到达聚合，不能理解为每 5 分钟才处理一次请求。另测试 1/3/6 小时规划和 5/15/30 分钟周期。

五、统一能耗与碳账本

本版采用六台常开 8-GPU 主机、六个准入槽位，共同观察窗口仍为 12 小时。单主机 IT 功率 =1500+8×175+(760—175)× 忙碌槽位数。固定空闲电量 250.56kWh，活动 IT 增量 585W/忙碌槽位，再乘 PUE1.2。共享功率及所有闲置 GPU 只计一次；增加准入槽位不增加主机底座。不可用不自动断电。

estimated_energy_kwh 仅为服务秒 ×585×1.2/3.6e6。server_config 的 p_idle_w/p_busy_w 为整机空闲 2900W 及单忙碌槽位 3485W，差值 585W。完整设施电量 = 固定主机底座 + 忙碌增量 + 网络 + 单独控制。碳依实际地区/小时分段积分，不把跨小时服务都归到开始时刻。L 服务时长已经缩放，不再乘 3。

路由、控制与网络假设保持原口径；控制 10W 是单独增量计算工作代理，主优化 0.01 秒/次是假设，真实 wall 另记，并有实测 wall 进入 DES 的敏感性。所有碳结果为条件仿真，不是实际部署实测。

六、实际运行与测试范围

先跑手算及事件边界测试，再 100、500、1000、7335 逐规模扩展。最终表共引用 336 个完成的唯一配置—重复组合，不是 336 个独立统计样本；各敏感性有意共用随机数。主比较完整 7335 个、3 个扰动重复；主要敏感

性 1000 个，失效边界及时域 500 个；另完成 7335 完整轨迹的 2 倍需求、局部故障和双地区降容压力实验。

上游 21 项、系统 25 项测试通过。每个采用的运行额外核查终态 ID 守恒、选模冻结、地区许可、时间分解、物理不重叠、容量准入、公共随机条件和能量分解。软件测试通过不等于业务零超时。

手算例：两个 10 秒 L 任务、单副本，DE/FR/ES 强度 300/30/200，其他约束允许时在 FR 顺序执行；设施忙碌增量功率 702W，增量碳为 $20\times702/3.6e6\times30=0.117g$。代码核对位置、互斥和能量。跨小时 3590 至 3610 秒、前后强度 100/200，碳强度时间积分为 3000，代码一致。

汇总 130217 次优化决策包含单请求枚举，不全部是 HiGHS 调用。status=0 共 130026、不可行/无候选 188、超时 3；均有日志与回退。最大单批 1354 变量、2434 约束。没有建立 7335 请求逐秒全时域巨型 MILP，也没有声称其全局最优。

七、实际结果怎么解释（本次重新求解）

第三问研究结果：固定 Pre-LightGBM 后的时空调度

实际运行范围

最终结果使用 336 个完成且通过逐请求不变量检查的唯一配置—重复组合；不同配置有意共用随机数，并非 336 个独立统计样本。跨实验复用相同配置的缓存，不把复用计作新随机重复。主要比较使用完整 7335 请求、3 个固定公共服务扰动重复。需求/故障/延迟/预测敏感性采用 1000 个固定分层请求，复杂度边界和规划窗口用 500 个固定分层请求；已完成的完整规模需求 2 倍及两故障压力实验列在 experiment_full_stress.csv。规模基准为 100/500/1000/7335，每规模 1 次运行，不能据此给出普遍扩展性保证。

数据是 2025 全年三个地区逐小时提供方 CO2e 快照，合计 26280 行；生命周期为主、直接 CO2e 为独立敏感性。没有生成真实回答、质量标签或碳观测。合成 RouterBench 到达过程仅平移到 2025-01-02 UTC，非真实 2025 业务流量。原 PDF 未提供，研究问题依据用户所附第三问文字。

四策略完整请求主结果

策略	CO2e/g 均值 ±SD	电量/kWh	P95/s	完成率/%	服务违反率/%	求解 wall/s
Fixed Local	41374.061915 ± 1.350524	252.289256	5.2170	99.4229	0.5771	0.0000
Greedy Carbon	41288.146559 ± 2.062467	252.298557	4.8889	99.7228	0.2772	0.0000
Offline MILP Oracle*	41230.781144 ± 0.704884	252.304027	1800.4554	99.9773	0.0227	5.0384
Causal MILP-MPC	41233.013855 ± 0.553889	252.302935	14.8803	99.9227	0.0773	3.0524

*Oracle 允许完整未来碳/需求/容量信息，但采用有限候选和顺序离线 MILP 批次，仅在各个有限批次求解；不是原始全轨迹随机系统的全局最优解或有证书的理论下界。主表平均和 SD 来自同一 3 个服务扰动种子的条件重复，不代表硬件、训练或数据选择不确定性。

相对 Fixed，MPC 总 CO2e 均值差为 141.048060g（0.34091%）；相对 Greedy 差为 55.132705g。必须结合完成率和违反率解读，不能把少服务请求产生的低电量当作优化收益。所有输入都有完成/失败记录，历史固定模型质量均值为 0.776141786，各策略相同；服务未交付造成的有效效用降低另列，不能归因于 S/L 质量变化。

MPC 总电量相对 Fixed 改变 +0.013679kWh；本场景的节碳来自用电地点/时刻改变，并不等同于节电。更多成功交付、跨区网络与控制计算都可能增加电量，固定空闲底座又限制了设施总量收益。

表中平均/P95/P99 响应与等待仅在完成请求上定义，失败率及有效交付效用使用全部输入作分母；不能只比较条件延迟而忽略丢失服务。Oracle 明显更长的等待反映其对未来信息的利用，不能被较低碳数值掩盖。延迟放宽时的曲线并非精确 Pareto 前沿：候选网格、分批承诺和随机执行会使曲线非单调。

RQ1：空间调度收益及其上限

实际数值见主表和图 01。空间差异通过活跃增量、传输和控制开销影响净收益；物理机群始终为 6 台常开 8-GPU DGX，每地区 S/L 各一台，但各池只准入 1 个服务槽位，合计 48 张安装 GPU、6 个可调度槽位。所有未使用或不可用池仍计整机空闲功率。MPC 主情景空闲碳均值 41140.351200g，占总量 99.7753%；空闲电量固定为 250.56kWh。因此即使把大部分推理移到低碳地区，总设施减排也可能很小。不能用活跃部分的减排百分比替代总量减排百分比。

RQ2：复杂调度与简单贪心

Greedy 在当前可用/估计可排队地区按最近可见碳选择，不主动寻找未来低碳小时。MPC 优化已经到达的等待请求，可通过在绿色地区排队、避免争抢或短期保留容量改变位置/开始时间。主策略 Persistence 未来曲线恒定，不能预知未来低碳小时，因此不会有凭空的未来预测收益。收益来源需用逐请求地区、等待和 solver 日志解释，不归于模型选型变化。

需求和故障数值见 aggregate_demand.csv、aggregate_availability.csv；不同情景仍使用同一请求 ID、模型、配置容量、种子和 12 小时观察窗口。故障只关闭新任务准入，已运行任务完成；不可用不意味着断电。高负载容量下降表示外部争用槽位，没有虚构额外任务的耗电。复杂策略在紧约束下可能超时、回退或服务失败，均计入统计。

1000 请求需求敏感性均值（P95 和等待只针对完成请求；失败全量计入违反率）：

load	strategy	CO2e/g	P95/s	主动等待/s	服务违反/%
0.5	Greedy	41148.669942	4.5638	0.0000	0.0000
0.5	MPC	41147.442222	5.5173	0.6941	0.0000
1.0	Greedy	41149.044805	4.5667	0.0000	0.0000
1.0	MPC	41147.183280	5.9913	0.7842	0.0000
2.0	Greedy	41150.894209	4.6079	0.0000	0.0000
2.0	MPC	41147.363794	8.2473	1.0275	0.0000

完整 7335 轨迹压力组均值：

setting	strategy	CO2e/g	P95/s	主动等待/s	服务违反/%
high_load_capacity_reduction_load1.0	Fixed	41363.404529	6.3586	0.0000	6.5349
high_load_capacity_reduction_load1.0	Greedy	41310.180835	5.1859	0.0000	1.2406
high_load_capacity_reduction_load1.0	MPC	41259.984816	15.0384	3.7818	1.2724
high_load_capacity_reduction_load1.0	Oracle	41254.222136	1800.4219	196.8120	0.5499
local_failure_load1.0	Fixed	41365.311999	5.6465	0.0000	3.0948
local_failure_load1.0	Greedy	41286.412771	4.9113	0.0000	0.3181
local_failure_load1.0	MPC	41232.903137	14.8563	3.6926	0.0773
local_failure_load1.0	Oracle	41230.495441	1800.4540	208.1229	0.0273
normal_load2.0	Fixed	41369.778186	6.7049	0.0000	1.8678
normal_load2.0	Greedy	41319.925318	5.4289	0.0000	0.6180
normal_load2.0	MPC	41285.876711	92.7684	21.9551	0.2181

setting	strategy	CO2e/g	P95/s	主动等待/s	服务违反/%
normal_load2.0	Oracle	41303.820102	1800.4576	247.5608	0.2454

RQ3：主动等待与排放

图 02、experiment_delay.csv 改变非实时服务完成预算和最大等待的倍率 0.25/0.5/1/2；实时完成预算保持 30 秒，等待按倍率改变。每组都使用完全相同的 12 小时观察窗口，避免扩大 deadline 时新增空闲电量混入比较。intentional_delay 含控制计算和延后 dispatch，queue_wait 仅从传输完成后到执行开始，response 分解逐请求验证。

Oracle 可以看见未来小时的变化，反映有限候选下的信息头寸；Persistence 不能预测趋势，不能把 Oracle 的时间收益称为可部署收益。图中红叉表示有服务约束违反，不是合格 Pareto 点。actual 服务随机超出保守估计时可能产生 late/drop，完整可行性没有由离散计划自动保证。

delay_scale	strategy	CO2e/g	P95/s	主动等待/s	服务违反/%
0.25	MPC	41147.273541	5.5566	0.6986	0.0000
0.25	Oracle	41147.022426	9.3490	10.5581	0.0000
0.5	MPC	41147.231432	5.7772	0.7300	0.0000
0.5	Oracle	41147.104482	29.8463	36.5439	0.0000
1.0	MPC	41147.183280	5.9913	0.7842	0.0000
1.0	Oracle	41146.874529	1800.3505	141.2500	0.0000
2.0	MPC	41146.884710	6.2363	0.8161	0.0000
2.0	Oracle	41146.975839	3600.4833	625.6744	0.0000

RQ4：何时复杂路由不值得

严格判定使用共同完成输入且双方服务约束全部满足，并且 Greedy—MPC 总 CO2e>0。results/boundary_classification.csv 给出每个轴每个采样点三个重复的净收益均值、SD、约束和是否全部重复值得；图 07 显示净收益过零与服务失效。边界是 500 请求固定子集上的单因素样点，不能称为普遍临界常数。相邻采样点状态发生变化时，只报告区间：

```
[
  {
    "axis": "defer_fraction",
    "sampled_transition_brackets": [],
    "universal_threshold": false
  },
  {
    "axis": "forecast_noise",
    "sampled_transition_brackets": [
      [
        0.3,
        0.8
      ]
    ],
    "universal_threshold": false
  },
  {
    "axis": "load",
    "sampled_transition_brackets": [],
    "universal_threshold": false
  },
  {
    "axis": "network_scale",
    "sampled_transition_brackets": [
      [
        1.0,
        10.0
      ]
    ],
    "universal_threshold": false
  },
  {
    "axis": "solve_delay_seconds",
    "sampled_transition_brackets": [
      [
        0.1,
        1.0
      ]
    ],
    "universal_threshold": false
  },
  {
    "axis": "spread",
    "sampled_transition_brackets": [
      [
        0.0,
        0.25
      ]
    ],
    "universal_threshold": false
  }
]
```


空间碳差异接近 0 时，迁移的传输/控制代价可能超过活跃收益；拥堵与故障时，低碳地区会受容量与等待限制；传输时延放大时，一部分跨区选择不再满足截止；每次优化计算较慢时，控制能耗和延迟可能抹掉微小收益；预测扰动过大则可能错过低碳位置/时间。以上因果方向必须以实际采样表验证，未出现的交叉不推断精确阈值。

预测、计算开销与最优性限制

Persistence 和历史同小时均值只读取发布时点之前已完成的观测小时；噪声是在合法预测上作固定键随机乘性扰动，未以 future actual 为中心加噪。issued_at 与 observed_end 在 solver 日志逐次检查。数据来自 2026 年的回溯快照，缺少真正的 2025 发布版本；这里是条件历史再预测，不能声称恢复了真实生产时可见数值。

同一固定发布网格上的事后预测误差（数值仅用于事后评价）：

method	evaluation_values	MAE_gco2e_kwh	RMSE_gco2e_kwh
persistence_0.0	321	33.95785	63.439088
historical_hour_0.0	321	42.611651	74.136046
persistence_0.3	321	50.509693	77.113872
persistence_0.8	321	90.428683	141.259423
perfect_future_actual_oracle	321	0.0	0.0

预测情景下的实际调度结果：

setting	strategy	CO2e/g	P95/s	主动等待/s	服务违反/%
historical_hour_0.0	MPC	41147.362826	114.0164	49.5305	0.0000
perfect_foresight_restricted	Oracle	41146.874529	1800.3505	141.2500	0.0000
persistence_0.0	MPC	41147.183280	5.9913	0.7842	0.0000
persistence_0.3	MPC	41147.325556	11.0330	3.1067	0.0000
persistence_0.8	MPC	41149.575339	11.3771	3.1259	0.0000

主实验把新增优化控制计算时间设为显式情景 0.01 秒/次，并分别记录真实 wall 求解时间；不能把 10ms 写成实测 MILP 性能。experiment_measured_controller.csv 另实际运行“0.01 秒 + 当次 wall 时间”进入 DES 与能耗的敏感性。图 08 给出真实程序运行时间，不用模型时钟冒充 wall 时间。规划时域 1/3/6 小时、周期 5/15/30 分钟的结果在 experiment_horizon.csv；另有到达/紧迫事件触发更新，周期不是唯一触发。绝大多数等待上限小于 1 小时，较长时域未必增加候选价值。

实测 wall 开销进入模型时的 500 请求结果：

strategy	CO2e/g	P95/s	主动等待/s	服务违反/%
Fixed	41156.270133	4.6496	0.0000	0.2000
Greedy	41144.341915	4.6544	0.0000	0.0000
MPC	41143.846499	5.3352	0.6622	0.0000
Oracle	41143.644089	1800.3808	142.7865	0.0000

所有 MILP 使用 HiGHS1.2.2/SciPy1.9.1，单次 0.2 秒预算，记录 status/gap/变量约束数/请求 ID 和 fallback 原因。单请求有限候选用精确枚举并独立标记，不能把枚举次数写成 HiGHS 调用次数。solver_summary.json 汇总实际状态。保守服务倍率 1.35 仅用于占用/可行性规划，真实服务仍为继承估计 × 公共扰动，未再乘 L 倍率。

条件结论

完整主实验 MPC 的平均服务违反率为 0.077255%。因此若该值非零，就不能声称当前策略已满足零违反的部署要求，也不能仅凭正碳差宣称复杂策略“值得”。可将本结果作为改进预测、准入、安全余量或业务 SLA 之前的条件研究。真实碳曲线是历史提供方数据；网络、服务器功率/PUE、容量故障、需求映射和控制增量功率是显式假设；推理时间由事前估计和公共随机数模拟。任何节碳数字均是条件反事实结果，不是实际 GPT-4/Mixtral 部署减排。

当前结果已经使用新版功率重新优化并在 DES 执行，不是对旧调度轨迹简单乘系数。功率继承当前 Task1 配置和 task2/runs/experiment：共享 1500W/台、8 张 GPU、每 GPU 空闲 175W、忙碌 760W；整机空闲 2900W、一个忙碌槽位 3485W、PUE1.2。共享/空闲是未实测假设，760W 是特定基准配置代理，不是 GPT-4/Mixtral 整机实测。旧 175/250W 情景保存在 archives/legacy_power_175_250_20261017，不能与本轮数据混合。

所有图表都由已完成实验文件生成。当前版本 Task1/Task2 和数据准备文件 563 个 SHA256 保护项保持不变；旧版保护记录仍在归档。旧数据准备接口 21 项合成测试继续验证，旧全数据验证器因路径/功率字段已过时而被显式替代，当前冻结路由、保存 Pre、训练长度、服务估计及能耗由新源验证程序逐项复查。没有下载生成模型或调用付费 LLM。

八、怎么运行

8.1 已有环境下，先只看结果

当前运行环境 Python3.9.13、SciPy1.9.1/HiGHS1.2.2；无需重新训练模型或调用 API。打开 PowerShell：

```
Set-Location 'D:\EuroMCM\EuroMCM-project\TASK 3\task3_model'
python --version
python -B -X utf8 run_all.py --phase report
```

最后一行读取已完成实验、核对相关保护/输入记录、重建报告与图表，**不重跑调度实验。**终端出现 `REPORTS AND FIGURES COMPLETE 336 completed unique runs` 表示当前最终实验表完成报告生成。

若更换机器，可用 `requirements.txt` 了解依赖，用 `configs/requirements-lock.txt` 核对本次确切环境。上游只读兼容测试还需要 LightGBM、torch 等原环境依赖；不要把缺库误判为调度模型不可行。保留原解释器环境最方便，无需安装 SimPy 或下载模型权重。

8.2 按阶段从头执行

```
python -B -X utf8 run_all.py --phase audit
python -B -X utf8 run_all.py --phase test
python -B -X utf8 run_all.py --phase pilot
python -B -X utf8 run_all.py --phase scale
python -B -X utf8 run_all.py --phase experiments
python -B -X utf8 run_all.py --phase full-stress
python -B -X utf8 run_all.py --phase report
```

阶段	实际动作
audit	只读上游接口审计、碳规范化、时间对齐及预测输入
test	运行系统 pytest，写 Junit 测试记录
pilot	再跑系统测试，四策略 100 请求试验，建立规模门槛
scale	四策略 100/500/1000/7335，逐规模不变量检查
experiments	主比较、需求、可用性、延期、预测、边界、规划窗口、碳口径、实测控制开销
full-stress	7335 完整轨迹需求翻倍及两种故障
report	聚合 CSV、配对差、验证报告、11 组 PNG/SVG 和完整性清单

一条命令执行上述顺序：

```
python -B -X utf8 run_all.py --phase all
```

已有配置/代码/数据指纹一致的完成结果会复用缓存；`all` 不等于强制重新计算。没有 metrics 的试跑不作成功缓存。若需独立重算，先备份现有结果，再将本目录 `results/runs` 移为本目录内的归档缓存目录，随后运行 all；不要动上游文件。重新计算可能因硬件/时间限制产生不同超时及轨迹，固定种子不等于真实 wall 完全相同。

仅运行单元测试：

```
python -B -X utf8 -m pytest -q -p no:cacheprovider tests
```

仅试一个 100 请求 MPC（已有 audit 派生输入时）：

```
python -B -X utf8 -c "from src.experiments import run_one; print(run_one('MPC', n=100, rep=0))"
```

这会生成/读取一个运行目录，不会自动将单次结果加入正式实验汇总表。

8.3 参数在哪里改

正式模型参数在 `configs/core.json` 的 model，包含规划时域、重优化周期、安全余量、单批大小、求解预算、预测方法、控制功率/延迟和观察窗口。重复编号与敏感性子集规模也在该文件。

`configs/experiment_protocol.json` 记录实验协议；实际轴取值网格在 `src/experiments.py`。`run_all.py` 中的 pilot/scale 规模序列也由代码传入；仅修改 core 的 `pilot_sizes` 不会改变该序列。根目录 `config.json` 只是兼容旧接口的快照，不是正式模型入口。

修改配置前保存原配置/结果；修改后重新运行受影响阶段再 report，不把不同版本结果混成一张表。改变规模/实验网格时，也要同步核对图表标题和报告中的固定规模说明。延长 deadline 或降低需求可能需要预先设置更长、各策略共同的观察窗口，不能只给某策略增加窗口。

九、怎么看结果

9.1 推荐阅读顺序

1. `RESULTS_zh.md`：实验范围、主表、四个 RQ、压力/预测/边界及限制。
2. `figures/01_strategy_comparison.png` 与 `10_full_trace_stress.png`：主结果与真实运行的完整轨迹压力结果。
3. `figures/02_delay_tradeoff.png` 与 `07_complexity_failure_boundary.png`：等待代价与失效条件。
4. `MODEL_FORMULATION.md`：论文用数学定义和保证边界。
5. `VALIDATION_REPORT.md` 及 `results/audit/final_validation.json`：软件通过、未验证元数据和物理假设。
6. 对可疑或重点结论，从实验表 run_id 追到逐请求、事件和能量账本。

9.2 CSV 各是什么

文件	一行是什么/用途
`results/experiment_main.csv`	某策略某 rep 的完整 7335 请求主实验，含 run_id
`results/aggregate_main.csv`	按策略聚合的均值、SD、计数
`results/experiment_demand.csv` 等	每个参数组合/rep 的实际运行结果
`results/experiment_full_stress.csv`	完整 7335 请求压力组
`results/paired_comparisons.csv`	公共随机数下的策略配对差
`results/boundary_classification.csv`	采样点净收益、SD 和服务合格判定
`results/boundary_brackets.json`	相邻采样点的转变区间，不是精确临界根
`results/forecast_accuracy.csv`	事后预测误差，actual 仅用于评分
`results/run_inventory.csv`	区分最终采用、早期未采用及未完成试跑
`results/artifact_manifest.json`	最终采用文件的 SHA256 清单

`completion_rate/service_violation_rate` 在 CSV 是 0–1 比例，报告才乘 100 展示百分数。`co2e_g` 是克，除 1000 得到 kg。`rep` 是公共扰动重复编号，不是模型重新训练编号。不要拿 1000 子集总碳直接与 7335 主实验比较优劣。

查看主实验原始行：

```
python -B -X utf8 -c "import pandas as pd; d=pd.read_csv('results/experiment_main.csv');
↪  print(d[['strategy','rep','co2e_g','energy_kwh','p95_response_s','completion_rate','service_vio
↪  lation_rate','run_id']].to_string(index=False))"
```

9.3 从 run_id 追到每个请求

每个 `results/runs/<run_id>/` 包含：

- `config.json`、`input_ids.json`、`common_random_conditions.json`：配置、输入群体及扰动证明。
- `metrics.json`：单次全部指标。
- `requests.csv.gz`：每个请求唯一终态、地区、时间、失败原因、违反标记及事后质量。
- `events.csv.gz`：到达、开始、结束、容量变化和控制事件。

- `energy_ledger.csv.gz`：idle、active_increment、network、controller 逐项电量及碳。
- `solver_log.jsonl.gz`：求解状态、engine、规模、gap、耗时及回退信息。
- 主 MPC rep0 另有 `issued_forecasts.csv.gz`，检查实际发出的预测及发布时间。

pandas 可直接读取 gz，不必先手工解压。下面自动定位主 MPC rep0：

```
@'
from pathlib import Path
import pandas as pd
d = pd.read_csv('results/experiment_main.csv')
run_id = d.loc[(d.strategy == 'MPC') & (d.rep == 0), 'run_id'].iloc[0]
p = Path('results/runs') / run_id
q = pd.read_csv(p / 'requests.csv.gz')
print('运行目录:', p.resolve())
print(q[['request_id', 'selected_model', 'region', 'arrival_s',
         'dispatch_s', 'service_start_s', 'completion_s', 'status']]
      .head(20).to_string(index=False))
print('失败原因:')
print(q.loc[q.status == 'failed', 'failure_reason'].value_counts())
ledger = pd.read_csv(p / 'energy_ledger.csv.gz')
print('四项能量/碳分解:')
print(ledger.groupby('component')[['energy_kwh', 'co2e_g']].sum())
'@ | python -B -X utf8 -
```

时间列 `_s` 是相对于对齐锚点的秒数。可用 `anchor + pd.to_timedelta(q['service_start_s'], unit='s')` 转回 UTC，anchor 从 `results/data/alignment.json` 读取。失败请求没有开始/完成时刻是合理 NaN，不等于请求从统计消失。

`runtime_seconds` 是程序执行 wall，`solver_wall_seconds` 是求解/有限候选求解部分 wall 总和，`modelled_optimizer_seconds` 是进入仿真时钟的控制预算。三者与单个请求的 `response_s` 不同。solver status=0 也只说明该受限模型在求解容差内，不能证明全部请求准时；status=1 是超时，2 是不可行/无候选，需结合回退日志。

9.4 十一组图各回答什么

图	阅读重点
01_strategy_comparison	总量与非空闲部分分开看，同时看完成请求 P95
02_delay_tradeoff	放宽等待后的碳变化，红叉表示违反，非严格 Pareto 前沿
03_regional_load	MPC 各地区实际并行负载的 5 分钟均值
04_actual_carbon_intensity	实际碳曲线，只作环境/事后展示，非 MPC 未来输入
05_mpc_dispatch_trace	到达、主动延后和实际执行，包含长延迟示例
06_demand_sensitivity	1000 子集的需求倍率，不替代全量压力实验
07_complexity_failure_boundary	500 子集净收益过零及服务失效
08_scale_runtime	实测 100/500/1000/7335 运行时间，单次规模基准
09_capacity_and_forecast	1000 子集的容量与预测影响
10_full_trace_stress	完整 7335 请求高负载及故障，必须与主图一起读
11_power_migration_comparison	区分旧结果、旧计划新功率计价、新功率重新调度

PNG 适合快速查看，SVG 适合论文排版缩放。

十、论文应当如何落结论

以第七章本次实际运行的碳差、延迟、完成与违反率回答 RQ，不再引用旧 175/250W 场景的 0.70%。区分固定计划重计价与新功率重新优化；比较方法和完整数据见 DGX 功率更新说明。六台常开主机使空闲底座占比很大，调度的活动增量收益不能替代设施总收益。若任一服务约束不满足，不能仅凭碳差为正判定严格部署值得。

真实碳曲线与仿真请求/功率/服务必须区分；没有全问题全局最优、真实商业模型硬件迁移或实际部署减排证明。确切 GWP/as-of 版本、匹配硬件测量及独立质量留出仍待补充。