第三问研究结果：固定 Pre-LightGBM 后的时空调度

实际运行范围

最终结果使用 336 个完成且通过逐请求不变量检查的唯一配置—重复组合；不同配置有意共用随机数，并非 336 个独立统计样本。跨实验复用相同配置的缓存，不把复用计作新随机重复。主要比较使用完整 7335 请求、3 个固定公共服务扰动重复。需求/故障/延迟/预测敏感性采用 1000 个固定分层请求，复杂度边界和规划窗口用 500 个固定分层请求；已完成的完整规模需求 2 倍及两故障压力实验列在 experiment_full_stress.csv。规模基准为 100/500/1000/7335，每规模 1 次运行，不能据此给出普遍扩展性保证。

数据是 2025 全年三个地区逐小时提供方 CO2e 快照，合计 26280 行；生命周期为主、直接 CO2e 为独立敏感性。没有生成真实回答、质量标签或碳观测。合成 RouterBench 到达过程仅平移到 2025-01-02 UTC，非真实 2025 业务流量。原 PDF 未提供，研究问题依据用户所附第三问文字。

四策略完整请求主结果

策略	CO2e/g 均值±SD	电量/kWh	P95/s	完成率/%	服务违反率/%	求解 wall/s
Fixed Local	41374.061915 ± 1.350524	252.289256	5.2170	99.4229	0.5771	0.0000
Greedy Carbon	41288.146559 ± 2.062467	252.298557	4.8889	99.7228	0.2772	0.0000
Offline MILP Oracle*	41230.781144 ± 0.704884	252.304027	1800.4554	99.9773	0.0227	5.0384
Causal MILP-MPC	41233.013855 ± 0.553889	252.302935	14.8803	99.9227	0.0773	3.0524

*Oracle 允许完整未来碳/需求/容量信息，但采用有限候选和顺序离线 MILP 批次，仅在各个有限批次求解；不是原始全轨迹随机系统的全局最优解或有证书的理论下界。主表平均和 SD 来自同一 3 个服务扰动种子的条件重复，不代表硬件、训练或数据选择不确定性。

相对 Fixed，MPC 总 CO2e 均值差为 141.048060g（0.34091%）；相对 Greedy 差为 55.132705g。必须结合完成率和违反率解读，不能把少服务请求产生的低电量当作优化收益。所有输入都有完成/失败记录，历史固定模型质量均值为 0.776141786，各策略相同；服务未交付造成的有效效用降低另列，不能归因于 S/L 质量变化。

MPC 总电量相对 Fixed 改变 +0.013679kWh；本场景的节碳来自用电地点/时刻改变，并不等同于节电。更多成功交付、跨区网络与控制计算都可能增加电量，固定空闲底座又限制了设施总量收益。

表中平均/P95/P99 响应与等待仅在完成请求上定义，失败率及有效交付效用使用全部输入作分母；不能只比较条件延迟而忽略丢失服务。Oracle 明显更长的等待反映其对未来信息的利用，不能被较低碳数值掩盖。延迟放宽时的曲线并非精确 Pareto 前沿：候选网格、分批承诺和随机执行会使曲线非单调。

RQ1：空间调度收益及其上限

实际数值见主表和图 01。空间差异通过活跃增量、传输和控制开销影响净收益；物理机群始终为 6 台常开 8-GPU DGX，每地区 S/L 各一台，但各池只准入 1 个服务槽位，合计 48 张安装 GPU、6 个可调度槽位。所有未使用或不可用池仍计整机空闲功率。MPC 主情景空闲碳均值 41140.351200g，占总量 99.7753%；空闲电量固定为 250.56kWh。因此即使把大部分推理移到低碳地区，总设施减排也可能很小。不能用活跃部分的减排百分比替代总量减排百分比。

RQ2：复杂调度与简单贪心

Greedy 在当前可用/估计可排队地区按最近可见碳选择，不主动寻找未来低碳小时。MPC 优化已经到达的等待请求，可通过在绿色地区排队、避免争抢或短期保留容量改变位置/开始时间。主策略 Persistence 未来曲线恒定，不能预知未来低碳小时，因此不会有凭空的未来预测收益。收益来源需用逐请求地区、等待和 solver 日志解释，不归于模型选型变化。

需求和故障数值见 aggregate_demand.csv、aggregate_availability.csv；不同情景仍使用同一请求 ID、模型、配置容量、种子和 12 小时观察窗口。故障只关闭新任务准入，已运行任务完成；不可用不意味着断电。高负载容量下降表示外部争用槽位，没有虚构额外任务的耗电。复杂策略在紧约束下可能超时、回退或服务失败，均计入统计。

1000 请求需求敏感性均值（P95 和等待只针对完成请求；失败全量计入违反率）：

load	strategy	CO2e/g	P95/s	主动等待/s	服务违反/%
0.5	Greedy	41148.669942	4.5638	0.0000	0.0000
0.5	MPC	41147.442222	5.5173	0.6941	0.0000
1.0	Greedy	41149.044805	4.5667	0.0000	0.0000
1.0	MPC	41147.183280	5.9913	0.7842	0.0000
2.0	Greedy	41150.894209	4.6079	0.0000	0.0000
2.0	MPC	41147.363794	8.2473	1.0275	0.0000

完整 7335 轨迹压力组均值：

setting	strategy	CO2e/g	P95/s	主动等待/s	服务违反/%
high_load_capacity_reduction_load1.0	Fixed	41363.404529	6.3586	0.0000	6.5349
high_load_capacity_reduction_load1.0	Greedy	41310.180835	5.1859	0.0000	1.2406
high_load_capacity_reduction_load1.0	MPC	41259.984816	15.0384	3.7818	1.2724
high_load_capacity_reduction_load1.0	Oracle	41254.222136	1800.4219	196.8120	0.5499
local_failure_load1.0	Fixed	41365.311999	5.6465	0.0000	3.0948
local_failure_load1.0	Greedy	41286.412771	4.9113	0.0000	0.3181
local_failure_load1.0	MPC	41232.903137	14.8563	3.6926	0.0773
local_failure_load1.0	Oracle	41230.495441	1800.4540	208.1229	0.0273
normal_load2.0	Fixed	41369.778186	6.7049	0.0000	1.8678
normal_load2.0	Greedy	41319.925318	5.4289	0.0000	0.6180
normal_load2.0	MPC	41285.876711	92.7684	21.9551	0.2181
normal_load2.0	Oracle	41303.820102	1800.4576	247.5608	0.2454

RQ3：主动等待与排放

图 02、experiment_delay.csv 改变非实时服务完成预算和最大等待的倍率 0.25/0.5/1/2；实时完成预算保持 30 秒，等待按倍率改变。每组都使用完全相同的 12 小时观察窗口，避免扩大 deadline 时新增空闲电量混入比较。intentional_delay 含控制计算和延后 dispatch，queue_wait 仅从传输完成后到执行开始，response 分解逐请求验证。

Oracle 可以看见未来小时的变化，反映有限候选下的信息头寸；Persistence 不能预测趋势，不能把 Oracle 的时间收益称为可部署收益。图中红叉表示有服务约束违反，不是合格 Pareto 点。actual 服务随机超出保守估计时可能产生 late/drop，完整可行性没有由离散计划自动保证。

delay_scale	strategy	CO2e/g	P95/s	主动等待/s	服务违反/%
0.25	MPC	41147.273541	5.5566	0.6986	0.0000
0.25	Oracle	41147.022426	9.3490	10.5581	0.0000
0.5	MPC	41147.231432	5.7772	0.7300	0.0000
0.5	Oracle	41147.104482	29.8463	36.5439	0.0000
1.0	MPC	41147.183280	5.9913	0.7842	0.0000
1.0	Oracle	41146.874529	1800.3505	141.2500	0.0000
2.0	MPC	41146.884710	6.2363	0.8161	0.0000
2.0	Oracle	41146.975839	3600.4833	625.6744	0.0000

RQ4：何时复杂路由不值得

严格判定使用共同完成输入且双方服务约束全部满足，并且 Greedy—MPC 总 CO2e>0。results/boundary_classification.csv 给出每个轴每个采样点三个重复的净收益均值、SD、约束和是否全部重复值得；图 07 显示净收益过零与服务失效。边界是 500 请求固定子集上的单因素样点，不能称为普遍临界常数。相邻采样点状态发生变化时，只报告区间：

```
[
  {
    "axis": "defer_fraction",
    "sampled_transition_brackets": [],
    "universal_threshold": false
  },
  {
    "axis": "forecast_noise",
    "sampled_transition_brackets": [
      [
        0.3,
        0.8
      ]
    ],
    "universal_threshold": false
  },
  {
    "axis": "load",
    "sampled_transition_brackets": [],
    "universal_threshold": false
  },
  {
    "axis": "network_scale",
    "sampled_transition_brackets": [
      [
        1.0,
        10.0
      ]
    ],
    "universal_threshold": false
  },
  {
    "axis": "solve_delay_seconds",
    "sampled_transition_brackets": [
      [
        0.1,
        1.0
      ]
    ],
    "universal_threshold": false
  },
  {
    "axis": "spread",
    "sampled_transition_brackets": [
      [
        0.0,
        0.25
      ]
    ],
    "universal_threshold": false
  }
]
```


空间碳差异接近 0 时，迁移的传输/控制代价可能超过活跃收益；拥堵与故障时，低碳地区会受容量与等待限制；传输时延放大时，一部分跨区选择不再满足截止；每次优化计算较慢时，控制能耗和延迟可能抹掉微小收益；预测扰动过大则可能错过低碳位置/时间。以上因果方向必须以实际采样表验证，未出现的交叉不推断精确阈值。

预测、计算开销与最优性限制

Persistence 和历史同小时均值只读取发布时点之前已完成的观测小时；噪声是在合法预测上作固定键随机乘性扰动，未以 future actual 为中心加噪。issued_at 与 observed_end 在 solver 日志逐次检查。数据来自 2026 年的回溯快照，缺少真正的 2025 发布版本；这里是条件历史再预测，不能声称恢复了真实生产时可见数值。

同一固定发布网格上的事后预测误差（数值仅用于事后评价）：

method	evaluation_values	MAE_gco2e_kwh	RMSE_gco2e_kwh
persistence_0.0	321	33.95785	63.439088
historical_hour_0.0	321	42.611651	74.136046
persistence_0.3	321	50.509693	77.113872
persistence_0.8	321	90.428683	141.259423
perfect_future_actual_oracle	321	0.0	0.0

预测情景下的实际调度结果：

setting	strategy	CO2e/g	P95/s	主动等待/s	服务违反/%
historical_hour_0.0	MPC	41147.362826	114.0164	49.5305	0.0000
perfect_foresight_restricted	Oracle	41146.874529	1800.3505	141.2500	0.0000
persistence_0.0	MPC	41147.183280	5.9913	0.7842	0.0000
persistence_0.3	MPC	41147.325556	11.0330	3.1067	0.0000
persistence_0.8	MPC	41149.575339	11.3771	3.1259	0.0000

主实验把新增优化控制计算时间设为显式情景 0.01 秒/次，并分别记录真实 wall 求解时间；不能把 10ms 写成实测 MILP 性能。experiment_measured_controller.csv 另实际运行“0.01 秒 + 当次 wall 时间”进入 DES 与能耗的敏感性。图 08 给出真实程序运行时间，不用模型时钟冒充 wall 时间。规划时域 1/3/6 小时、周期 5/15/30 分钟的结果在 experiment_horizon.csv；另有到达/紧迫事件触发更新，周期不是唯一触发。绝大多数等待上限小于 1 小时，较长时域未必增加候选价值。

实测 wall 开销进入模型时的 500 请求结果：

strategy	CO2e/g	P95/s	主动等待/s	服务违反/%
Fixed	41156.270133	4.6496	0.0000	0.2000
Greedy	41144.341915	4.6544	0.0000	0.0000
MPC	41143.846499	5.3352	0.6622	0.0000
Oracle	41143.644089	1800.3808	142.7865	0.0000

所有 MILP 使用 HiGHS1.2.2/SciPy1.9.1，单次 0.2 秒预算，记录 status/gap/变量约束数/请求 ID 和 fallback 原因。单请求有限候选用精确枚举并独立标记，不能把枚举次数写成 HiGHS 调用次数。solver_summary.json 汇总实际状态。保守服务倍率 1.35 仅用于占用/可行性规划，真实服务仍为继承估计 × 公共扰动，未再乘 L 倍率。

条件结论

完整主实验 MPC 的平均服务违反率为 0.077255%。因此若该值非零，就不能声称当前策略已满足零违反的部署要求，也不能仅凭正碳差宣称复杂策略“值得”。可将本结果作为改进预测、准入、安全余量或业务 SLA 之前的条件研究。真实碳曲线是历史提供方数据；网络、服务器功率/PUE、容量故障、需求映射和控制增量功率是显式假设；推理时间由事前估计和公共随机数模拟。任何节碳数字均是条件反事实结果，不是实际 GPT-4/Mixtral 部署减排。

当前结果已经使用新版功率重新优化并在 DES 执行，不是对旧调度轨迹简单乘系数。功率继承当前 Task1 配置和 task2/runs/experiment：共享 1500W/台、8 张 GPU、每 GPU 空闲 175W、忙碌 760W；整机空闲 2900W、一个忙碌槽位 3485W、PUE1.2。共享/空闲是未实测假设，760W 是特定基准配置代理，不是 GPT-4/Mixtral 整机实测。旧 175/250W 情景保存在 archives/legacy_power_175_250_20261017，不能与本轮数据混合。

所有图表都由已完成实验文件生成。当前版本 Task1/Task2 和数据准备文件 563 个 SHA256 保护项保持不变；旧版保护记录仍在归档。旧数据准备接口 21 项合成测试继续验证，旧全数据验证器因路径/功率字段已过时而被显式替代，当前冻结路由、保存 Pre、训练长度、服务估计及能耗由新源验证程序逐项复查。没有下载生成模型或调用付费 LLM。